



APRENDIZAJE DE MÁQUINA

INTRODUCCIÓN

Especialización en Inteligencia Artificial
FIUBA

Dr. Ing. Facundo Adrián Lucianna
Esp. Lic. María Carina Roldán

INTRODUCCIÓN

- Materia de 7 (siete) clases teórico-prácticas y 1 (una) clase de consulta.
- Las clases se impartirán con diapositivas y desarrollo en notebooks.
- Estructura de las clases:
 - 10 minutos de repaso de la clase anterior.
 - 3 (tres) bloques de 50 minutos de contenido teórico-práctico.
 - 2 (dos) recreos de 10 minutos.

INTRODUCCIÓN

- **Aula virtual**
 - <https://campusposgrado.fi.uba.ar/course/view.php?id=251>
- **Repositorio de la materia**
 - https://github.com/FIUBA-Posgrado-Inteligencia-Artificial/aprMaqI_CEIA
- **Consultas**
 - foro de consulta en el aula virtual
- **Correo** (las consultas generales envíenlas con copia a los dos)
 - Facundo Adrián Lucianna: facundolucianna@gmail.com
 - María Carina Roldán: macroldan@fi.uba.ar

TRABAJO PRÁCTICO FINAL

CONSIGNA Y ENTREGA

- El trabajo práctico final deberá implementarse y entregarse dentro de los **tres (3) días posteriores a la última clase**.
- El trabajo deberá realizarse en grupos de un mínimo de dos (2) y un máximo de seis (6) integrantes. Se podrán realizar excepciones únicamente con un justificativo debidamente fundamentado.
- El trabajo consiste en la implementación de un modelo de Machine Learning sobre un conjunto de datos a elección.

FORMATO DE ENTREGA

- El trabajo podrá entregarse en cualquier formato, preferentemente en un notebook de Jupyter (.ipynb). También se aceptará su presentación mediante Google Colab o un enlace a un repositorio.

TRABAJO PRÁCTICO FINAL (cont.)

ASPECTOS A CONSIDERAR

- El enfoque principal de este trabajo es la etapa de Machine Learning: la aplicación, manejo y evaluación de modelos.
- Si bien el procesamiento de datos y el feature engineering son pasos esenciales para la aplicación del modelo, en esta materia tendrán menor relevancia.
- Se deberá justificar la elección de las herramientas utilizadas y presentar un desarrollo teórico correcto.
- No olvidar incluir las referencias bibliográficas correspondientes.

ESTRUCTURA SUGERIDA (Storytelling)

Introducción al problema (contexto, tipo de problema) → Datos (descripción y preparación) → Entrenamiento (baseline, algoritmos, justificación) → Métricas y evaluación → Conclusiones.

DATASETS

¿No tienen dataset?

- Kaggle: <https://www.kaggle.com/datasets>
- Awesome public datasets: <https://github.com/awesomedata/awesome-public-datasets>
- Real world fake data: <https://sonsofhierarchies.com/real-world-fake-data/>
- Maven analytics: <https://www.mavenanalytics.io/data-playground>

Si siguen sin encontrar un dataset, les dejamos algunos en el aula virtual.

PROGRAMA



Introducción a Machine Learning. Definiciones. Ciclo de vida de un proyecto de Aprendizaje Automático. Metodología para construir modelos.



Aprendizaje supervisado. Clasificador KNN. Medidas de distancia. Encontrando a los vecinos. Métodos de Ajuste de los hiperparámetros. Frameworks de búsqueda.



Máquinas de vectores de soporte. Maximal Margin Classifier. Clasificador de Vector de soportes. Máquinas de vectores de soporte en regresión.



Árboles de decisión. Árboles de clasificación y árboles de regresión.

PROGRAMA

5

Métodos de ensamble. Modelos que votan. Bagging. Bosques aleatorios. Boosting.





6

Aprendizaje No Supervisado. Clustering. K-Means. Hierarchical clustering. Modelo de Mixtura Gaussiana. Suma de cuadrados intracluster. Índice de la silueta. Fuerza de predicción.

7

Calibración de modelos. Discriminación vs. Calibración. Métodos de Calibración.

BIBLIOGRAFÍA



- Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python - Peter Bruce (Ed. O'Reilly)
- The Elements of Statistical Learning - Trevor Hastie (Ed. Springer)
- An Introduction to Statistical Learning - Gareth James (Ed. Springer)
- Pattern Recognition And Machine Learning - Christopher Bishop (Ed. Springer)

***APRENDIZAJE
AUTOMÁTICO***

APRENDIZAJE AUTOMÁTICO

Tal como se aprendió en Inteligencia Artificial, **Aprendizaje Automático** se entiende como:

Una computadora que observa algunos datos, construye un modelo basado en ellos y utiliza ese modelo como una hipótesis sobre el mundo, además de como una pieza de software capaz de resolver problemas.

- Recibe un conjunto de datos y aprende por sí misma.
- Reconoce patrones entre los datos y realiza predicciones.
- No requiere que una persona programe instrucciones de forma explícita.



¿Cuándo usar aprendizaje automático?

- El Aprendizaje Automático no resuelve todos los problemas.
- Incluso cuando puede aplicarse, la solución obtenida puede no ser la mejor.
- Antes de iniciar un proyecto debemos evaluar si realmente es necesario.

¿Cuándo usar aprendizaje automático?

Sin datos no hay aprendizaje

- Para entrenar un modelo necesitamos una cantidad suficiente de datos.
- Los datos deben estar disponibles o ser posibles de recolectar.
- La calidad de los datos suele ser más importante que el algoritmo.

Muchas empresas siguen un enfoque de *"fake-it-til-you-make-it"* ; es decir, lanzan un producto que ofrece **predicciones hechas por humanos** en lugar de modelos de Machine Learning, con la esperanza de utilizar los datos generados para entrenar posteriormente dichos modelos.

¿Cuándo usar aprendizaje automático?

Debe existir un patrón

- El ML funciona cuando existen patrones en los datos.
- Si no hay patrón, no hay nada que aprender.
- Algunas tareas tienen soluciones más simples y efectivas.
- ¿conviene usar ML en estos casos?
 - *calcular la trayectoria de un proyectil*
 - *detectar spam*
 - *recomendar películas*

¿Cuándo usar aprendizaje automático?

No es suficiente con que exista un patrón

- No siempre es evidente que exista una relación útil.
- El dataset puede ser insuficiente.
- El algoritmo puede no ser capaz de capturarla.
- Ejemplo:
 - *Relación entre los tweets de Elon Musk y el precio de ciertas criptomonedas.*

¿Cuándo usar aprendizaje automático?

Los modelos solo pueden resolver problemas que requieran respuestas predictivas.

Este enfoque puede resultar atractivo cuando se puede beneficiar de una gran cantidad de predicciones baratas, aunque aproximadas.

- *¿Cómo será el clima mañana?*
- *¿Qué película verá un usuario después?*
- *¿Qué cliente abandonará el servicio?*

¿Cuándo usar aprendizaje automático?


Entrenamiento y producción deben parecerse (drift)

- Los datos utilizados en el entrenamiento y los datos futuros sobre los que se aplicará el modelo deben provenir de distribuciones similares.
- Nunca sabemos con certeza si eso es así, pero podemos suponerlo.
- Si el supuesto falla, el rendimiento será deficiente.

¿Cuándo usar aprendizaje automático?

Los patrones cambian

- Cuando una tarea es **repetitiva**, cada patrón se repite varias veces, lo que facilita que las máquinas lo aprendan.
- Los patrones evolucionan con el tiempo. Cambian los usuarios, las culturas y las tecnologías.
- Los modelos deben actualizarse periódicamente.



Spam en 2012 $\neq$ Spam en 2020

¿Cuándo usar aprendizaje automático?

RIESGOS

- Los modelos se equivocan.
- Algunos errores pueden tener **consecuencias graves.**

Desarrollar vehículos autónomos es un desafío, ya que un error puede provocar la muerte. Aun así, muchas empresas continúan invirtiendo en su desarrollo, dado que estos vehículos tienen el potencial de salvar muchas vidas, una vez que sean estadísticamente más seguros que los conductores humanos.

¿Cuándo usar aprendizaje automático?

COSTOS

Las soluciones de Aprendizaje Automático suelen requerir una inversión inicial considerable en **datos, cómputo, infraestructura y talento**, por lo que su aplicación se justifica principalmente cuando el uso de dicha solución es frecuente o sostenido en el tiempo.

¿Cuándo NO usar aprendizaje automático?

- No es ético.
- Existe una solución simple que funciona bien.
- No hay datos suficientes.
- No existe un patrón aprendible.
- No es rentable.

DEFINICIONES

TERMINOLOGÍA BÁSICA

En Machine Learning generalmente se utilizan arrays 2D y notaciones vectoriales para referirse a los datos:

- Cada fila del array representa una **muestra, observación o dato puntual**.
- Cada columna corresponde a una **característica** (feature o atributo) de la observación.
- En el caso más general, habrá una columna que llamaremos **objetivo, label, etiqueta o respuesta**, y que representará el valor que se pretende predecir.

TERMINOLOGÍA BÁSICA

features

label

Position	Experience	Skill	Country	City	Salary (\$)
Developer	0	1	USA	New York	103100
Developer	1	1	USA	New York	104900
Developer	2	1	USA	New York	106800
Developer	3	1	USA	New York	108700
Developer	4	1	USA	New York	110400
Developer	5	1	USA	New York	112300
Developer	6	1	USA	New York	116100
Developer	7	1	USA	New York	117800


observación



TERMINOLOGÍA BÁSICA

Los algoritmos de Machine Learning tienen parámetros “internos” que no dependen directamente de los datos: son los **hiperparámetros**.

Por ejemplo, una red neuronal tiene como hiperparámetros la función de activación o la tasa de aprendizaje (learning rate).



Llamamos **generalización** a la capacidad de un modelo para realizar predicciones correctas utilizando datos nuevos.

TIPOS DE APRENDIZAJE


- **Aprendizaje supervisado:** los modelos se entrenan con un conjunto de ejemplos en los que los resultados de salida son conocidos.
- **Aprendizaje no supervisado:** busca encontrar información significativa en los datos sin usar respuestas conocidas, analizando datos que no están etiquetados.
- **Aprendizaje profundo:** usa redes neuronales artificiales con varias capas que se conectan entre sí, inspiradas en el funcionamiento del cerebro humano, para aprender a partir de los datos.

APRENDIZAJE SUPERVISADO

- Los modelos aprenden a partir de ejemplos con resultados conocidos y realizan ajustes en sus parámetros internos para adaptarse a los datos de entrada.
- Una vez entrenado, el modelo se evalúa mediante conjuntos de datos separados para medir su desempeño. Si los resultados son satisfactorios, podrá utilizarse para realizar predicciones sobre nuevos datos.



APRENDIZAJE SUPERVISADO




APRENDIZAJE SUPERVISADO

CLASIFICACIÓN

En un problema de **clasificación** el objetivo es predecir clases categóricas (valores discretos, no ordenados, que indican pertenencia a grupos).

Tipos de clasificación:

- binaria.
 - *Ejemplo: detección de spam (es spam / no es spam)*
- multiclase.
 - *Ejemplo: nivel socioeconómico de una persona (alta, media o baja).*




APRENDIZAJE SUPERVISADO

REGRESIÓN

En un problema de **regresión** hay un conjunto de variables predictoras (explicativas) y una variable de respuesta continua (resultado). Se trata de encontrar una relación entre dichas variables que nos proporcione un resultado continuo.

Regresión lineal: Dados X e y , se establece una línea recta que minimice la distancia entre los puntos de muestra y la línea ajustada. Luego, se utiliza la fórmula obtenida para predecir nuevos datos de salida.




Ejemplo de regresión: precio de casas en venta en una ciudad, dado el barrio, la cantidad de habitaciones, etc.

APRENDIZAJE NO SUPERVISADO

- El **agrupamiento o clustering** es una técnica exploratoria para analizar datos y formar grupos de elementos parecidos, sin tener conocimiento previo de su estructura.
- Cada grupo es un conjunto de objetos similares entre sí y diferentes de los de otros grupos.


Ejemplo: analizar el comportamiento de múltiples cadenas de comida y determinar cómo se agrupan en el mercado para evaluar sus verdaderos competidores.



APRENDIZAJE NO SUPERVISADO


La **reducción de dimensionalidad** es una técnica de aprendizaje no supervisado:

- analiza las variables de los datos sin usar una "etiqueta".
- detecta relaciones o correlaciones entre características.
- elimina ruido o información redundante.
- resume los datos en menos variables, pero conservando lo importante.




APRENDIZAJE PROFUNDO

- Esta arquitectura de múltiples capas permite abordar el análisis de datos de forma **no lineal**.
- La primera capa toma datos en bruto como entrada, los procesa, extrae información y la transfiere a la siguiente capa como salida.
- Cada capa procesa la información proporcionada por la capa anterior, y así sucesivamente hasta que los datos llegan a la capa final, donde se obtiene la predicción.
- Esta predicción se compara con el resultado conocido, y mediante un análisis inverso, el modelo es capaz de aprender los factores que conducen a salidas adecuadas.
- Es uno de los principales algoritmos utilizados en la creación de aplicaciones y programas para reconocimiento de imágenes.
- Para obtener buenos resultados, necesitamos muchos datos, y en general el entrenamiento es costoso.




CICLO DE VIDA

Ciclo de vida de un proyecto de ML



Ciclo de vida de un proyecto de ML



ENTENDIENDO EL NEGOCIO

Entendiendo el negocio

Cuando se trabaja en un proyecto de Aprendizaje Automático, los científicos de datos suelen enfocarse en **métricas técnicas**, como:

- precisión
- F1-score
- entre otras.

A menudo, los equipos invierten grandes recursos para mejorar una métrica del 94 % al 94,5 %

Pero la realidad es que, para la mayoría de las empresas, esas mejoras no importan, a menos que se traduzcan en **impacto comercial real**.

Entendiendo el negocio

Para que un proyecto de ML tenga éxito, es clave **conectar las métricas del modelo con los resultados del negocio**.

Algunas preguntas que conviene plantearse son:

- *¿Qué indicadores de negocio busca mejorar el sistema de ML?*
- *¿Más ingresos por publicidad?*
- *¿Mayor número de usuarios activos?*
- *¿Menor tasa de abandono?*

Es importante vincular las métricas del modelo con las métricas del negocio.

Entendiendo el negocio

Casos donde el impacto es fácil de medir

Una de las razones por las que la predicción de las tasas de clics en anuncios y la detección de fraude se encuentran entre los casos de uso más populares de ML en la actualidad es que es fácil asignar el rendimiento de los modelos a las métricas de negocio:

- Cada aumento en la tasa de clics genera ingresos publicitarios reales.
- Cada transacción fraudulenta detenida representa un ahorro de dinero real.

Entendiendo el negocio

Validar el impacto mediante experimentos

Para obtener una respuesta definitiva a la pregunta de cómo las métricas de ML influyen en las métricas del negocio, a menudo es necesario realizar experimentos. Muchas veces se utilizan pruebas como los experimentos A/B, eligiendo el modelo que conduce a mejores métricas comerciales, independientemente de si este modelo tiene mejores métricas de ML.

Entendiendo el negocio

Gestionar expectativas del negocio

A veces, es difícil manejar las expectativas del negocio.

Debido al hype que genera Machine Learning, es necesario ser realista acerca de los beneficios que puede ofrecer un modelo.


Algunos negocios pueden tener la idea de que el Aprendizaje Automático puede transformar una solución mágicamente de la noche a la mañana.

Mágicamente: Posible

De la noche a la mañana: No

PIPELINE DE MACHINE LEARNING

Pipeline de ML




Pipeline de ML

PREPROCESAMIENTO

- Es el **paso más importante**. Recordar: *Garbage in, garbage out ...*
- Usualmente, los datos se presentan en **formatos no óptimos** (o incluso inadecuados) para ser procesados por el modelo.
- Muchos algoritmos requieren que las características estén en la misma **escala** para optimizar su rendimiento, lo cual se logra frecuentemente aplicando técnicas de **normalización** o **estandarización** de los datos.
- En algunos casos, las características seleccionadas pueden estar **correlacionadas** y, por tanto, resultar **redundantes** para extraer información significativa. En estos casos, será necesario utilizar técnicas de **reducción dimensional** para comprimir las características en subespacios de menor dimensión.
- Realizar un **correcto análisis estadístico** es vital para garantizar que los datos estén preparados adecuadamente para el algoritmo que queremos utilizar.

Pipeline de ML

PREPROCESAMIENTO



Pipeline de ML

SELECCIÓN Y ENTRENAMIENTO DE MODELO

- Es esencial comparar los diferentes algoritmos de un grupo para entrenar y seleccionar el de **mejor rendimiento**. Para ello, es necesario **elegir una métrica** que permita medir dicho rendimiento.
- Cuando no tenemos nada para comparar inicialmente, definimos un **baseline** basado en una heurística sencilla. Esta servirá como referencia para evaluar el desempeño de los modelos que desarrollemos posteriormente.
- Para asegurarnos de que nuestro modelo funcionará adecuadamente con **datos reales**, podemos usar **validación cruzada** (*Cross Validation*) antes de utilizar el conjunto de **datos de prueba** para la evaluación final del modelo.
- En general, los **parámetros por defecto** de los algoritmos de Machine Learning proporcionados por las librerías no son los óptimos para nuestros datos, por lo que se utilizan técnicas de **optimización de hiperparámetros**.

Pipeline de ML

EVALUAR Y PREDECIR CON DATOS NUEVOS

Una vez que hemos seleccionado y ajustado un modelo con nuestro conjunto de **datos de entrenamiento**, podemos usar los **datos de prueba** para estimar el **rendimiento del modelo** en datos nuevos. Esto nos permite hacer una **estimación del error de generalización** del modelo o evaluarlo utilizando alguna otra métrica.

Si el modelo cumple con nuestros objetivos, el siguiente paso es **ponerlo en producción** en el contexto en que se desea utilizar. En esta materia, *no abordaremos este paso.*

En la próxima clase veremos ...

Aprendizaje supervisado. Clasificador KNN. Medidas de distancia. Encontrando a los vecinos. Métodos de Ajuste de los hiper-parámetros. Frameworks de búsqueda.