



APRENDIZAJE DE MÁQUINA

APRENDIZAJE NO SUPERVISADO

Especialización en Inteligencia Artificial
FIUBA

Dr. Ing. Facundo Adrián Lucianna
Esp. Lic. María Carina Roldán


En la clase anterior vimos ...

Métodos de ensamble. Modelos que votan. Bagging. Bosques aleatorios. Boosting.

MÉTODOS DE ENSAMBLE

Al combinar las predicciones de varios modelos, es posible obtener un mejor desempeño que utilizando un único modelo.

A este conjunto de modelos se lo denomina **ensamble**.



MODELOS QUE VOTAN

La predicción final se obtiene combinando las predicciones individuales mediante una estrategia de votación:

Estrategia HARD VOTING

- Se basa en la moda de las predicciones.

Estrategia SOFT VOTING

- Se basa en promedios de predicciones. **Ventaja:** le da mayor peso a los modelos que tienen más confianza en su decisión.

Estrategia VOTING REGRESSOR

- Se basa en promedios de predicciones (problemas de regresión).


ESTRATEGIAS DE ENSAMBLE

Existen distintas estrategias para construir un ensamble. Entre las más utilizadas, vimos:

- Bagging (*bootstrap aggregating*)
- Bosques aleatorios (*Random Forest*)
- Boosting

BAGGING

Para realizar **Bagging** (*bootstrap aggregating*), utilizamos modelos que tengan mucha varianza y poco sesgo. Estos modelos se pueden entrenar en **paralelo**.



BOSQUES ALEATORIOS

Los **bosques aleatorios** (*Random Forests*) pueden considerarse una extensión del método **Bagging**.

El funcionamiento es similar, pero agregan un paso importante:

- En cada división se considera solo un **subconjunto aleatorio de atributos**.
- Una elección habitual es utilizar como cantidad de atributos, aproximadamente la raíz cuadrada del total de atributos disponibles.

Esta selección aleatoria hace que los árboles sean menos correlacionados entre sí, lo que aumenta el beneficio de combinar sus predicciones.

BOOSTING

Los métodos de **Boosting** construyen un ensamble combinando múltiples predictores para obtener un modelo más preciso.

A diferencia de Bagging, donde los modelos se entrenan de forma independiente, en Boosting el entrenamiento es **secuencial**: cada modelo se construye utilizando la información de los errores cometidos por los modelos anteriores.

Habitualmente se utilizan árboles de decisión poco profundos (*weak learners*), que individualmente tienen un desempeño modesto, pero cuya combinación permite obtener un modelo con una alta capacidad predictiva.

XGBOOST

Una de las librerías más utilizada en Boosting es XGBoost, una implementación de Gradient Boosting estocástico desarrollada por Tianqi Chen y Carlos Guestrin en la Universidad de Washington.



[XGBoost: A Scalable Tree Boosting System](#)

***APRENDIZAJE NO
SUPERVISADO***

APRENDIZAJE NO SUPERVISADO

¿Qué cambia respecto del aprendizaje supervisado?

- Tenemos un conjunto de datos con n observaciones y p atributos.
- No existe una variable respuesta (Y).
- Por lo tanto, el algoritmo no recibe ejemplos de cuál es la respuesta correcta.

APRENDIZAJE NO SUPERVISADO

¿Qué cambia respecto del aprendizaje supervisado?

La ausencia de Y tiene dos consecuencias importantes:

- No existe un objetivo de predicción claramente definido.
- Es mucho más difícil evaluar si el resultado obtenido es "correcto", porque no disponemos de una respuesta conocida contra qué comparar nuestras conclusiones.

APRENDIZAJE NO SUPERVISADO

¿Qué cambia respecto del aprendizaje supervisado?

El objetivo no es predecir sino **descubrir patrones o estructura en los datos** sin contar con una variable respuesta.

Ejemplos:

- *detectar grupos similares,*
- *encontrar relaciones entre observaciones,*
- *identificar patrones ocultos,*
- *resumir información compleja.*


CLUSTERING

CLUSTERING

Clustering o agrupación es un conjunto de técnicas de aprendizaje no supervisado cuyo objetivo es identificar grupos naturales dentro de un conjunto de datos.

La idea es formar grupos de manera que:

- las observaciones de un mismo grupo sean lo más similares posible entre sí.
- las observaciones sean muy diferentes de las que pertenecen a otros grupos.



CLUSTERING

Vamos a ver tres algoritmos de clustering, de los más famosos entre los múltiples que existen:

- K-Means
- Hierarchical clustering
- Modelos de mixtura gaussiana


*Antes de ver los algoritmos, debemos definir **qué significa que dos observaciones sean similares o diferentes**. Esta noción depende del dominio de aplicación y del conocimiento que se tenga sobre los datos.*

***MEDIDAS DE
DISTANCIA O SIMILITUD***

MEDIDAS DE DISTANCIA O SIMILITUD

La **distancia** es una medida que cuantifica el grado de similitud o diferencia entre dos observaciones.

↑ Distancia $\Rightarrow$ ↓ Similitud




MEDIDAS DE DISTANCIA O SIMILITUD

En clustering, la similitud entre observaciones suele medirse mediante una **función de distancia**.


En muchos casos se utilizan las mismas medidas de distancia que vimos al estudiar kNN:

- Euclidiana (módulo 2)
- Manhattan, taxi, city-block (módulo 1)
- Chebyshev (módulo infinito)
- Distancia coseno
- etc.




LINKAGE

El **linkage** es el método o criterio que define cómo se calcula la **distancia entre dos clusters**, a partir de las distancias individuales entre sus elementos.




TIPOS DE LINKAGE

SINGLE LINKAGE




distancia mínima entre todos los pares de puntos de los dos grupos

COMPLETE LINKAGE



distancia máxima entre todos los pares de puntos de los dos grupos


AVERAGE LINKAGE



promedio de todas las distancias

TIPOS DE LINKAGE

CENTROID LINKAGE



distancia entre los centroides de los grupos

Donde el
centroide del
cluster K se
calcula como:

$$Centroide = \frac{1}{|C_K|} \sum_{i \in C_k} x_i$$

MÉTODO WARD

No se basa en distancias
sino en la suma de los
cuadrados dentro de
cada cluster (**SSE**)

$$W(C_k) = \sum_{i \in C_k} \sum_{j=1}^p (x_{ij} - \bar{x}_j)^2$$

K-MEANS CLUSTERING




K-MEANS

K-means es un algoritmo de clustering que divide un conjunto de datos en K grupos (clusters) distintos y no superpuestos.

Es decir, cada observación se asigna a un único cluster y no quedan observaciones sin asignar.

Para realizar la agrupación, primero debemos especificar el número deseado de clusters **K**. Luego, el algoritmo asignará cada observación a uno y solo uno de los K clusters.

K-MEANS



K-MEANS

La idea detrás de K-Means es encontrar un agrupamiento en el que las observaciones de un mismo cluster sean lo más similares posible entre ellas. Para ello, se busca **minimizar la variación dentro de los clusters**.

El objetivo es minimizar:
$$\sum_{k=1}^K W(C_k)$$

donde $C_1, \dots, C_K$ representan los clusters.
y $W(C_k)$ es la variación dentro del cluster k .

K-MEANS

¿Cómo medimos la variación?

Existen distintas formas de definir $W(C_k)$. En k-means se utiliza la **suma de cuadrados intracluster**, basada en la distancia euclídeana:

$$W(C_k) = \frac{1}{|C_K|} \sum_{i,i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2$$

K-MEANS

¿Cómo medimos la variación?

En lugar de calcular todas las distancias entre pares de observaciones, es más eficiente representar cada cluster mediante su centroide:

$$Centroide = \frac{1}{|C_K|} \sum_{i \in C_k} x_i$$

Ahora podemos calcular la distancia intracluster de una forma más simple:

$$W(C_k) = \sum_{i \in C_k} \sum_{j=1}^p (x_{ij} - \overline{x_j})^2$$

K-MEANS

La inercia

La suma de las variaciones de todos los clusters recibe el nombre de **inercia**:

$$Inercia = \sum_{k=1}^K W(C_k)$$

El objetivo de k-means es **minimizar la inercia**.

Como resolver exactamente este problema es computacionalmente costoso, K-Means utiliza un algoritmo iterativo que reduce la inercia en cada paso hasta converger a una solución estable.

K-MEANS

Algoritmo

1. **Inicializar.** Seleccionar K centroides iniciales (generalmente de forma aleatoria).


2. **Iterar:**

- a. Asignar cada observación al centroide más cercano (habitualmente utilizando la distancia euclídeana).
- b. Recalcular los centroides de los K grupos.
- c. Calcular el valor de inercia.

3. **Finalizar** cuando:

- a. las asignaciones ya no cambien, o
- b. se alcance el número máximo de iteraciones.

K-MEANS




K-MEANS

- En cada iteración del algoritmo, la **inercia** disminuye o permanece constante.
- El algoritmo converge a una solución en un número finito de iteraciones.
- La solución alcanzada corresponde a un mínimo local de la inercia, que no necesariamente coincide con el mínimo global.

K-MEANS

Distintas ejecuciones del algoritmo pueden converger a mínimos locales diferentes. Entonces es recomendable **ejecutar el algoritmo múltiples veces** y seleccionar la mejor solución (la que tenga menor inercia).



***MÉTODOS PARA
DETERMINAR EL NÚMERO
ADECUADO DE CLUSTERS***

MÉTODOS PARA DETERMINAR EL NÚMERO ADECUADO DE CLUSTERS

¿Cómo elegir el número de clusters K?

Uno de los principales desafíos en los problemas de clustering es determinar el número adecuado de grupos K.


En la práctica, existen distintos métodos que ayudan a orientar esta elección, entre ellos:

- Método del codo (*Elbow Method*)
- Índice de la silueta (*Silhouette Score*)
- Fuerza de predicción (*Prediction Strength*)
- Otros criterios


MÉTODO DEL CODO (*Elbow method*)

Consiste en analizar cómo varía una métrica de calidad del agrupamiento (generalmente la inercia) a medida que aumenta el número de clusters.


1. Ejecutar el algoritmo de clustering para distintos valores de K .
2. Calcular una métrica de calidad (generalmente la inercia) para cada valor de K .
3. Graficar la métrica en función de K .
4. Observar el gráfico y buscar un punto de codo. El punto de codo es aquel donde la métrica (inercia) comienza a disminuir a una tasa más lenta. En otras palabras, es el punto donde aumentar el número de clusters produce una mejora cada vez menor.



MÉTODO DEL CODO (*Elbow method*)



En este caso 5 clusters parece ser óptimo.



Pero también hay otros valores posibles.
Hay casos inclusive donde es más difícil
determinar el codo.

Índice de la silueta (*Silhouette Score*)

Es una métrica que evalúa la calidad de un agrupamiento combinando dos conceptos:

- Cohesión: qué tan similares son las observaciones de un mismo cluster.
- Separación: qué tan diferentes son las observaciones de clusters distintos.

Un buen agrupamiento presenta:

- alta cohesión, y
- alta separación.

Índice de la silueta (*Silhouette Score*)

Cálculo

Para cada observación i se calcula:

- **COHESIÓN:** distancia promedio entre i y las demás observaciones de su propio cluster

$$a_i = \frac{1}{|C_I| - 1} \sum_{j \in C_I, i \neq j} d(i, j)$$

- **SEPARACIÓN:** menor distancia promedio entre i y las observaciones de otro cluster

$$b_i = \min_{J \neq I} \frac{1}{|C_J|} \sum_{j \in C_J} d(i, j)$$

Luego:

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}$$

Índice de la silueta (*Silhouette Score*)

Los valores del índice de silueta varían entre -1 y 1.

SEPARACIÓN

COHESIÓN



$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}$$

- Cercano a 1: la observación está mucho más cerca de su propio cluster que de cualquier otro.
- Cercano a 0: la observación está prácticamente igual de cerca de su cluster que del vecino. Probablemente esté en la frontera entre dos clusters.
- Cercano a -1: la observación está, en promedio, más cerca de otro cluster que del suyo. probablemente está mal asignada.

En la práctica, suele calcularse el promedio del índice de silueta de todas las observaciones. Cuanto mayor sea este promedio, mejor será la calidad del agrupamiento.

Índice de la silueta (*Silhouette Score*)

Los valores del índice pueden representarse mediante un **gráfico de silueta**, que permite visualizar el tamaño de cada cluster y qué tan bien asignada se encuentra cada observación.



Índice de la silueta (*Silhouette Score*)

Sin embargo, el uso más frecuente del índice es evaluar la calidad del agrupamiento y ayudar a seleccionar el número de clusters mediante el **promedio del índice de silueta**.



Fuerza de Predicción

Es un método para evaluar la calidad de un agrupamiento a partir de su **estabilidad**.


La **fuerza de predicción** evalúa qué tan reproducible es el agrupamiento cuando el algoritmo se aplica sobre distintos subconjuntos de los datos.

Si los clusters son "reales", estos deberían volver a aparecer al entrenar el algoritmo sobre otro subconjunto de los datos.

Fuerza de Predicción

Cálculo

1. Se divide el conjunto de datos en train y test.
2. Se entrena un modelo de clustering sobre cada subconjunto.



Fuerza de Predicción

Cálculo

3. Para cada cluster obtenido en test, se identifican los pares de observaciones que pertenecen al mismo cluster (matriz de co-miembros).

	0	1	2	3	4	5	6
0		1	1				
1	1		1				
2	1	1					
3							
4							
5							
6							

Fuerza de Predicción

Cálculo

4. Se verifica si esos mismos pares permanecen agrupados en el modelo entrenado con Xtrain.

	0	1	2	3	4	5	6
0		1	0				
1	1		1				
2	0	1					
3							
4							
5							
6							

Fuerza de Predicción

Cálculo

5. Para cada cluster se calcula la proporción de conexiones que se mantienen:

$$FP_k = \frac{\text{Conexiones que se mantuvieron}}{|C_k| (|C_k| - 1)}$$

Finalmente, la **fuerza de predicción** del agrupamiento se calcula como el mínimo valor obtenido entre todos los clusters:

$$FP = \min (FP_k)$$

Fuerza de Predicción

¿Por qué es un método tan utilizado?

La fuerza de predicción evalúa la **estabilidad del agrupamiento**.

- Si el número de clusters es adecuado, al dividir el conjunto de datos y volver a ejecutar el algoritmo se obtienen agrupamientos muy similares. En consecuencia, la mayoría de las conexiones entre observaciones se mantienen.
- Si el número de clusters no es adecuado, pequeñas variaciones en los datos producen agrupamientos diferentes. En este caso, muchas conexiones entre observaciones se pierden y la fuerza de predicción disminuye.


Fuerza de Predicción

¿Por qué es un método tan utilizado?

2 clusters → Agrupamiento inestable
→ Baja fuerza de predicción



3 clusters → Agrupamiento estable
→ Alta fuerza de predicción



Fuerza de Predicción

El enfoque visto puede extenderse naturalmente para utilizar **validación cruzada** y obtener una estimación más robusta de la estabilidad del agrupamiento.




Vamos a practicar un
poco ...

MODELOS DE MIXTURA GAUSSIANA (GMM)

Limitaciones de K-means


K-Means es un algoritmo simple y eficiente. Si tenemos bloques separados de datos, el algoritmo puede agruparlos rápidamente.



Limitaciones de K-means

... pero presenta algunas limitaciones importantes:


- Asigna cada observación a un único cluster, sin indicar el grado de incertidumbre de esa asignación.



Limitaciones de K-means

... pero presenta algunas limitaciones importantes:

- No tiene la flexibilidad para detectar clusters que no son esféricos.




MODELOS DE MIXTURA GAUSSIANA

Los **Modelos de Mixtura Gaussiana** (*Gaussian Mixture Models*, GMM) constituyen un enfoque distinto para realizar clustering.


A diferencia de K-Means, que asigna cada observación al centroide más cercano, los GMM modelan los datos como una **mezcla de distribuciones gaussianas** y realizan **asignaciones probabilísticas**.

MODELOS DE MIXTURA GAUSSIANA

- Mientras que en K-Means las asignaciones son rígidas, en GMM las asignaciones son probabilísticas.




clustering con K_Means




clustering con GMM

MODELOS DE MIXTURA GAUSSIANA

- Mientras que K-Means funciona mejor cuando los clusters son esféricos, GMM encuentra clusters con distintas formas y tamaños.



clustering con K_Means



clustering con GMM

MODELOS DE MIXTURA GAUSSIANA

Un **Modelo de Mixtura Gaussiana** supone que los datos fueron generados por una mezcla de K distribuciones normales multivariadas.

Cada componente de la mezcla se caracteriza por:

- una media μ_j ,
- una matriz de covarianza Σ_j ,
- un peso ϕ_j , que representa la probabilidad de que una observación provenga de esa componente, es decir, de una distribución gaussiana con parámetros μ_j y Σ_j .

$$f_X = \sum_{j=1}^k \phi_j f_{\mu_j \Sigma_j}$$

El problema es que no conocemos μ de cada distribución, σ ni ϕ . El **objetivo** es estimar todos estos valores a partir de los datos que tenemos.

MODELOS DE MIXTURA GAUSSIANA

Para estimar estos parámetros μ_j , Σ_j y ϕ_j utilizamos el algoritmo de máxima expectación (*Expectation-Maximization* o EM).


El algoritmo alterna entre dos tareas:

- estima la probabilidad de pertenencia de cada observación a cada una de las distribuciones;
- actualiza los parámetros de las distribuciones: μ_j , Σ_j y ϕ_j (para $j=1, \dots, K$)


Para simplificar, vamos a considerar un problema unidimensional con $K=2$.

MODELOS DE MIXTURA GAUSSIANA

Tenemos los siguientes datos (una variable):



El GMM supone que los datos fueron generados por una mezcla de 2 distribuciones normales univariadas:




El algoritmo tiene que estimar:

- μ_1, μ_2
- σ_1, σ_2
- ϕ_1, ϕ_2 (probabilidad de que una observación provenga de cada una de las dos componentes gaussianas)

y poder responder:

- ¿a qué componente pertenece? (para cada observación)



MODELOS DE MIXTURA GAUSSIANA

Algoritmo (simplificado para 1 variable y 2 clusters)

Para el caso unidimensional y dos clusters (K=2), tenemos:

$$f(x | \mu_1 \sigma_1^2) \leftarrow \frac{1}{\sqrt{2\pi\sigma_1^2}} e^{\frac{-(x-\mu_1)^2}{2\sigma_1^2}} \quad f(x | \mu_2 \sigma_2^2) \leftarrow \frac{1}{\sqrt{2\pi\sigma_2^2}} e^{\frac{-(x-\mu_2)^2}{2\sigma_2^2}}$$

Y tenemos que estimar los parámetros μ_1 , σ_1 , ϕ_1 , μ_2 , σ_2 y ϕ_2 .

Inicialización

- μ_1 , σ_1 , μ_2 y σ_2 se inicializan con valores al azar.
- $\phi_1 = \phi_2 = 1/k = 0,5$. Esto es, se le da el mismo peso a cada componente.

MODELOS DE MIXTURA GAUSSIANA

Algoritmo (simplificado para 1 variable y 2 clusters)

Iteración. Paso E (Expectation).

1. Para cada observación $i=1, \dots, N$, se calcula:

$$f(x | \mu_1 \sigma_1^2) \leftarrow \frac{1}{\sqrt{2\pi\sigma_1^2}} e^{\frac{-(x-\mu_1)^2}{2\sigma_1^2}} \quad f(x | \mu_2 \sigma_2^2) \leftarrow \frac{1}{\sqrt{2\pi\sigma_2^2}} e^{\frac{-(x-\mu_2)^2}{2\sigma_2^2}}$$

2. Para cada observación $i=1, \dots, N$, y cada cluster $j=1,2$, usando la regla de Bayes, se calcula la probabilidad de que la observación pertenezca a cada uno de los clusters:

$$b_i^{(1)} = \frac{f(x | \mu_1 \sigma_1^2)}{f(x | \mu_1 \sigma_1^2)\phi_1 + f(x | \mu_2 \sigma_2^2)\phi_2} \quad b_i^{(2)} = \frac{f(x | \mu_2 \sigma_2^2)}{f(x | \mu_1 \sigma_1^2)\phi_1 + f(x | \mu_2 \sigma_2^2)\phi_2}$$

MODELOS DE MIXTURA GAUSSIANA

Iteración. **Paso M (Maximization).**

Con las probabilidades calculadas en el paso anterior, se actualizan los parámetros de las distribuciones gaussianas.

3. Se computan nuevos valores de μ_1 , σ_1 , μ_2 y σ_2 :

$$\mu_1 \leftarrow \frac{\sum_{i=1}^N b_i^{(1)} x_i}{\sum_{i=1}^N b_i^{(1)}}$$

$$\sigma_1 \leftarrow \frac{\sum_{i=1}^N b_i^{(1)} (x_i - \mu_1)^2}{\sum_{i=1}^N b_i^{(1)}}$$

$$\mu_2 \leftarrow \frac{\sum_{i=1}^N b_i^{(2)} x_i}{\sum_{i=1}^N b_i^{(2)}}$$

$$\sigma_2 \leftarrow \frac{\sum_{i=1}^N b_i^{(2)} (x_i - \mu_2)^2}{\sum_{i=1}^N b_i^{(2)}}$$


4. Se actualizan ϕ_1 y ϕ_2 :

$$\phi_1 \leftarrow \frac{1}{N} \sum_{i=1}^N b_i^{(1)}$$

$$\phi_2 \leftarrow \frac{1}{N} \sum_{i=1}^N b_i^{(2)}$$

Finalización. Se itera hasta que los valores de μ_1 , σ_1 , μ_2 y σ_2 no cambian.

MODELOS DE MIXTURA GAUSSIANA



MODELOS DE MIXTURA GAUSSIANA

¿Cómo armamos los clusters?

Ya tenemos las K distribuciones gaussianas, es decir, ya ajustamos los parámetros μ_j , σ_j y ϕ_j .

Para cada observación X_i la asignación a cada cluster es probabilística:
 X_i pertenece al cluster j con probabilidad $b_i^{(j)}$.

$$b_i^{(j)} = \frac{f(x | \mu_j \sigma_j^2)}{f(x | \mu_1 \sigma_1^2) \phi_1 + f(x | \mu_2 \sigma_2^2) \phi_2}$$

Si se desea una partición "dura", se asigna la observación al cluster con mayor probabilidad.

MODELOS DE MIXTURA GAUSSIANA


En el caso multidimensional, cada componente gaussiana posee una **matriz de covarianza**. La forma en que se define esta matriz (que es un hiperparámetro más del modelo) determina el tamaño, forma y orientación que pueden adoptar los clusters.

Algunas opciones:

- Covarianza diagonal
- Covarianza esférica
- Covarianza completa


MODELOS DE MIXTURA GAUSSIANA

- **Covarianza diagonal:** cada dimensión tiene una varianza propia, pero se asume que no existe correlación entre los atributos.




MODELOS DE MIXTURA GAUSSIANA

- **Covarianza esférica:** todas las dimensiones comparten la misma varianza, generando clusters aproximadamente esféricos (similares a los obtenidos con K-Means).



MODELOS DE MIXTURA GAUSSIANA

- **Covarianza completa:** permite correlación entre los atributos, dando lugar a clusters elípticos con cualquier orientación. Es la opción más flexible, aunque también la más costosa computacionalmente.



MODELOS DE MIXTURA GAUSSIANA

Similar al caso de K-Means, establecer la cantidad de clusters es un paso inicial para aplicar este modelo.



Podemos resolverlo con las técnicas que vimos, particularmente con **fuerza de predicción**.



Vamos a practicar un
poco ...

MODELOS DE MIXTURA GAUSSIANA



Estos modelos gaussianos también nos permiten estimar densidades.



En este caso GMM no genera buenos clusters ...

MODELOS DE MIXTURA GAUSSIANA

... pero se puede usar GMM para modelar la distribución (i.e. con 16 componentes).



Una vez obtenido el modelo, podemos generar nuevas muestras al azar de nuestra distribución.




MODELOS DE MIXTURA GAUSSIANA

Para el caso de estimación de densidad, la estimación del mejor número de clusters se puede hacer con usando:

- el criterio de información de Akaike (AIC)
- el criterio de información Bayesiana (BIC)

Se ajustan varios modelos GMM con distintos valores de K (por ejemplo, de 1 a 10), se calculan el AIC o el BIC para cada uno, y el mejor K es el que minimiza esos valores.

MODELOS DE MIXTURA GAUSSIANA





HIERARCHICAL CLUSTERING

HIERARCHICAL CLUSTERING

Una (potencial) desventaja de los modelos anteriores es que requieren que especifiquemos el número de clusters.

El **clustering jerárquico** es una alternativa que no tiene ese prerequisite.



HIERARCHICAL CLUSTERING



El **clustering jerárquico** es una técnica de aprendizaje no supervisado cuyo objetivo es organizar las observaciones en una **estructura jerárquica** según su similitud.

A diferencia de otros métodos de clustering, no produce una única partición de los datos, sino una secuencia de agrupamientos representada mediante una estructura en forma de árbol.

Una de sus principales ventajas es que permite explorar diferentes números de clusters sin necesidad de especificarlos previamente, lo que facilita la interpretación y el descubrimiento de patrones en los datos.


HIERARCHICAL CLUSTERING. Dendrograms.

Un **dendrograma** es una representación visual de los datos y la jerarquía de clusters a la que pertenecen. Cada hoja es una observación.




HIERARCHICAL CLUSTERING. Dendrogramas.

A medida que subimos en el árbol, algunas hojas empiezan a fusionarse en ramas, y luego las ramas se fusionan con hojas o con otras ramas. Las fusiones corresponden a observaciones que son similares entre sí.



cada hoja es una observación




La longitud de las ramas (altura) indica la distancia entre las observaciones o clusters.

HIERARCHICAL CLUSTERING. Dendrogramas.

Gráficamente, se pueden identificar diferentes números de clusters trazando una línea horizontal y deslizándola hacia arriba o hacia abajo.

La altura del corte determina el número de clusters (# de líneas verticales atravesadas por el corte).



HIERARCHICAL CLUSTERING

El algoritmo que construye el clustering jerárquico consiste en combinar iterativamente clusters similares.

Para determinar qué tan similares son dos clusters, necesitamos primero definir:

- un método para medir la **distancia** intra-cluster, es decir, la distancia entre dos observaciones de un mismo cluster. Por ejemplo, la distancia euclidiana.
- un **linkage** o método para medir la distancia inter-cluster.

HIERARCHICAL CLUSTERING

Algoritmo

1. **Inicialización.** Cada observación se considera un cluster separado.
2. **Iteración:**
 - a. Se computa la distancia entre todos los pares de clusters (usando el linkage elegido).
 - b. Se Identifica el par de clusters con menor distancia inter-cluster (es decir, los dos más similares) y se fusionan.
 - c. Se itera hasta que haya un único cluster.


En el caso del linkage **Ward**, la distancia inter-cluster es el **aumento de la SSE** al combinarlos. Este método, como k-means, busca clusters compactos y homogéneos.



Vamos a practicar un
poco ...


EJEMPLO PRÁCTICO

Un ejemplo de aplicación de estos algoritmos es la clasificación de tipos de coberturas de suelo: valle, montaña, cuerpos de agua, etc...



EJEMPLO PRÁCTICO

Un ejemplo de aplicación de estos algoritmos es la clasificación de tipos de coberturas de suelo: valle, montaña, cuerpos de agua, etc...





En una imagen satelital un pixel (observación) puede tener asociados muchos valores (features), entre ellos los valores del espectro visible (RGB).

Queremos clasificar los píxeles de la imagen.
¿Qué método podemos usar?

EJEMPLO PRÁCTICO



Podemos tomar una muestra de 1000 píxeles y con k-means hacer una primera clasificación.

El ejemplo de la derecha es el resultado de hacer una clasificación con $k=20$.







EJEMPLO PRÁCTICO

Esas 20 clases son las nuevas observaciones. Con ellas hacemos un clustering jerárquico.



EJEMPLO PRÁCTICO



En la próxima clase veremos ...

Calibración de modelos. Discriminación vs. Calibración. Métodos de calibración.