



CALIBRACIÓN DE MODELOS

APRENDIZAJE DE MÁQUINA - CEIA - FIUBA

Dr. Ing. Facundo Adrián Lucianna

Esp. Lic. María Carina Roldán

REPASO CLASE ANTERIOR

- Aprendizaje no supervisado
- Clustering
- K-Means
- Metodo del codo e Indice de la silueta
- Modelo de mixtura Gaussiana
- Clustering jerárquico

APRENDIZAJE NO SUPERVISADO

Para que usaríamos este tipo de aprendizaje?

Lo que buscamos en aprendizaje no supervisado es descubrir **una estructura sobre la base del conjunto de datos**. A diferencia de los problemas de aprendizaje supervisado, que buscamos predecir un resultado.


En un caso particular, es cuando queremos encontrar en los datos conjuntos que responden de una forma similar, es decir agrupamientos que *a priori* no son evidentes.

Por ejemplo, un sitio de compras podría intentar identificar grupos de compradores con historiales de navegación y compras similares, así como artículos que sean de particular interés para los compradores dentro de cada grupo.

CLUSTERING

Clustering o agrupación se refiere a un conjunto amplio de técnicas para encontrar subgrupos o clusters en un dataset.

Cuando agrupamos las observaciones, buscamos dividir las en grupos distintos de modo que las observaciones dentro de cada grupo sean **similares entre sí**, mientras que las observaciones en otro grupo sean bastante **diferentes** de las del primero.



CLUSTERING

Vimos tres algoritmos de clustering de los más famosos:


- **K-Means**
- **Hierarchical Clustering**
- **Modelo de Mixtura Gaussiana**

MEDIDAS DE DISTANCIA O SIMILITUD

En **kNN** vimos las medidas de distancias, en clustering, se utilizan las mismas medidas para indicar que tan diferente o similares son.

- **Distancia de Manhattan**
- **Distancia euclidiana**
- **Distancia de Chebyshev**
- **Distancia de Minkowski**

$$d_p(a, b) = \left(\sum_{i=1}^n (a_i - b_i)^p \right)^{1/p}$$



K-MEANS

Una forma de resolver esto de una forma más eficiente es calcular el centroide del cluster y calcular la distancia con respecto a ese punto.

El centroide de un cluster se calcula de la siguiente forma:

$$\textit{Centroide} = \frac{1}{|C_K|} \sum_{i \in C_k} x_i$$

Entonces, ahora podemos calcular la distancia intra-cluster más sencillamente:

$$W(C_k) = \sum_{i \in C_k} \sum_{j=1}^p (x_{ij} - \bar{x}_j)^2$$

K-MEANS


Y ahora buscamos minimizar la suma de las distancias intra-cluster que es lo que se conoce como **inercia**:

$$Inercia = \sum_{k=1}^K W(C_k)$$

Y ahora sí, el problema de minimización es más eficiente, minimizar $\{\sum_{k=1}^K W(C_k)\}_{C_1, \dots, C_K}$

El proceso es iterativo, y se va minimizando de a pasos hasta que llegue a un valor estable, siempre en dirección que reduce la inercia.

K-MEANS





MÉTODO DEL CODO



ÍNDICE DE LA SILUETA

Este índice nos permite graficar los clusters (incluso cuando se tienen más de dos dimensiones), ver el tamaño de cada uno y evaluar qué tan segura es la pertenencia de cada observación a su cluster.




MODELO DE MIXTURA GAUSSIANA

Un *Gaussian Mixture Model* (GMM) intenta encontrar una mezcla de distribuciones de probabilidad gaussianas multidimensionales que modelen mejor cualquier conjunto de datos de entrada.

En el caso más simple, los GMM se pueden utilizar para encontrar conglomerados de la misma manera que k-means.

Pero debido a que GMM contiene un modelo probabilístico, también es posible encontrar asignaciones probabilísticas.




MODELO DE MIXTURA GAUSSIANA

Un *Gaussian Mixture Model* (GMM) intenta encontrar una mezcla de distribuciones de probabilidad gaussianas multidimensionales que modelen mejor cualquier conjunto de datos de entrada.

En el caso más simple, los GMM se pueden utilizar para encontrar conglomerados de la misma manera que k-means.



Pero debido a que GMM contiene un modelo probabilístico, también es posible encontrar asignaciones probabilísticas.



HIERARCHICAL CLUSTERING

Una (potencial) desventaja de los modelos anteriores es que requieren que especifiquemos el número de clusters.

El clustering jerárquico es una alternativa que no tiene ese prerequisite.



HIERARCHICAL CLUSTERING

El **clustering jerárquico** es un algoritmo de aprendizaje automático no supervisado utilizado para agrupar datos en función de su similitud.

Su objetivo es organizar las observaciones en una estructura jerárquica tipo árbol, donde los elementos más parecidos se agrupan primero y los menos similares se combinan en niveles superiores.

Este método permite visualizar las relaciones entre los datos mediante un **dendrograma** y explorar diferentes números de clusters sin necesidad de definirlos previamente, lo que facilita la interpretación y el descubrimiento de patrones en los datos.

HIERARCHICAL CLUSTERING

Dendrogramas

→ Gráficamente, se pueden identificar diferentes números de clusters trazando una línea horizontal y deslizándola hacia arriba o hacia abajo.

La altura del corte determina el número de clusters (# de líneas verticales atravesadas por el corte).



CALIBRACIÓN DE MODELOS

CALIBRACIÓN DE MODELOS

¿Qué es la calibración?

Pensemos en una clasificación binaria.

Decimos que el modelo está calibrado si: “Cuando el modelo predice ‘0.7’, el evento realmente ocurre el 70% de las veces.”

La **calibración** **NO** evalúa si el modelo clasifica bien. La calibración evalúa si **las probabilidades son confiables**.

DISCRIMINACIÓN VS CALIBRACIÓN

La **discriminación** mide qué tan bien un modelo diferencia positivos de negativos.

Testea el *orden* de las predicciones, es decir, si un positivo recibe mayor probabilidad que un negativo.

La discriminación se puede evaluar con las métricas de clasificación:

- Matriz de confusión
- AUC–ROC
- Accuracy
- Precision/Recall
- F1
- Sensitivity/Specificity
- ...

DISCRIMINACIÓN VS CALIBRACIÓN

La **calibración** mide si las probabilidades reflejan frecuencias reales.

Si predice 0,7 ¿ocurre realmente el 70% de las veces?

Un modelo con buena discriminación ordena bien, pero no necesariamente está calibrado, es decir, que ordene bien no significa que prediga probabilidades confiables.

Ejemplo: Predice 0,99 para los positivos, pero si los verdaderos positivos ocurren solo el 40% de las veces, está **mal calibrado**.

MOTIVACIÓN

¿Por qué nos importaría que el modelo esté calibrado?

La calibración importa cuando no sólo clasificamos sino que tomamos decisiones en base a las probabilidades.

Casos críticos donde un 51% vs 99% cambia todo:

- *Medicina (Diagnósticos médicos)*
- *Finanzas (Riesgo crediticio)*
- *Vehículos autónomos*
- *Chatbots con riesgo alto (ej. legal, salud).*

La calibración permite elegir umbrales óptimos.

MOTIVACIÓN

Ejemplo: queremos decidir si dar o no un préstamo.

- El modelo sin calibrar dice probabilidad de default = 0.1
- El modelo calibrado dice = 0.22
- La clase es la misma (no-default), pero la decisión no.

Esto significa que si tenemos 100 clientes idénticos a este, y para todos el modelo predice una probabilidad de default de 0.1 (10%). Esto significa que **10 personas no pagarían**, pero si vamos a fin del mes, vemos que **22 personas no pagaron**.

MOTIVACIÓN

Ejemplo: queremos decidir si dar o no un préstamo.

Una empresa crediticia **se construye alrededor del riesgo**. Supongamos que el préstamo es de \$1000 y la ganancia (interés) es de \$200.

- Escenario usando el modelo sin calibrar:
 - Riesgo percibido: 10% de perder \$1000 = -\$100
 - Ganancia potencial: 90% de ganar \$200 = +\$180
 - Balance esperado: +\$80
 - Decisión: **Se da el préstamo.**

MOTIVACIÓN

Ejemplo: queremos decidir si dar o no un préstamo.

Una empresa crediticia **se construye alrededor del riesgo**. Supongamos que el préstamo es de \$1000 y la ganancia (interés) es de \$200.

- Escenario usando el modelo calibrado:
 - Riesgo percibido: 22% de perder \$1000 = -\$220
 - Ganancia potencial: 78% de ganar \$200 = +\$156
 - Balance esperado: -\$64
 - Decisión: **No se da el préstamo. Es una pérdida a largo plazo.**

PROBABILIDADES INGENUAS

Muchos modelos producen **probabilidades ingenuas** (no son frecuencias reales) y además muestran **excesiva confianza** (predicen valores extremos sin justificación).

Veamos algunos ejemplos...

PROBABILIDADES INGENUAS

Naive Bayes:

Tiende a empujar las probabilidades a los extremos absolutos (cerca de 0 o cerca de 1). Casi nunca va a dar salidas del tipo "*estoy 60% seguro*", en general da "*estoy 99.9% seguro*".

Por qué? Asume que todas las features son independientes entre sí.

Ejemplo: Si está prediciendo si un email es SPAM y ve las palabras "GRATIS" y "VIAGRA", el modelo suma la evidencia de ambas como si fueran hechos aislados. Esto "**infla**" la probabilidad artificialmente, volviéndolo excesivamente confiado.

PROBABILIDADES INGENUAS

Support Vector Machines:

Este modelo no está diseñado originalmente para dar probabilidades, sino para trazar una línea (hiperplano) y ver de qué lado caen los puntos. Sus "probabilidades" (cuando se fuerzan) suele usarse la distancia a la frontera.

Por qué? Al SVM solo le importa maximizar el margen (la distancia a la línea divisoria). No le importa la densidad de los datos. Un punto que está lejísimos de la línea se clasifica igual que uno que está justo en el borde.

PROBABILIDADES INGENUAS

Random Forest:

Este tipo de modelo tiende a promediar la salida de muchos árboles y eso hace que las salidas nunca sean muy cercanas a 1 o a 0.

Por qué? Si se tiene 100 árboles. Para que el modelo diga que la probabilidad es 1.0 (100%), absolutamente todos los 100 árboles tienen que votar "Sí".

PROBABILIDADES INGENUAS

Gradient Boosting (XGBoost):

Empuja las predicciones a 0.99 o 0.01 rápidamente porque encuentra reglas complejas que separan los casos.

Por qué? Cada árbol individual es lo suficientemente potente como para encontrar patrones muy específicos. Al sumar varios de estos, el modelo aprende a separar las clases demasiado bien en el entrenamiento.

MODELO BIEN CALIBRADO

Regresión logística

A diferencia de SVM (que busca márgenes geométricos) o Random Forest (que promedia votos), la Regresión Logística optimiza directamente la probabilidad (Log Loss).


Máxima Verosimilitud (Maximum Likelihood): El algoritmo busca los parámetros que hacen que las probabilidades predichas coincidan lo más posible con las frecuencias observadas en los datos reales. Por diseño, alinea su predicción con la realidad.

MEDICIÓN DE LA CALIBRACIÓN

MEDICIÓN DE LA CALIBRACIÓN

Para medir la calibración tenemos principalmente dos herramientas.


Reliability Diagram o Curva de calibración: es un gráfico que compara la probabilidad predicha y la frecuencia real. Si la línea está sobre la **diagonal**, significa que la calibración es perfecta. Las desviaciones indican **sobreestimación** o **subestimación**.



MEDICIÓN DE LA CALIBRACIÓN

Para construir esta gráfica se hace:

1. *Agrupar (Binning)*: Dividimos las predicciones en intervalos (ej. 10 grupos de 0 a 1).
2. *Calcular Eje X (Predicción)*: El promedio de las probabilidades predichas en ese grupo.
3. *Calcular Eje Y (Realidad)*: El porcentaje real de casos positivos en ese grupo.



MEDICIÓN DE LA CALIBRACIÓN

Para medir la calibración tenemos principalmente dos herramientas.

Brier Score: Es una métrica que mide qué tan lejos están las probabilidades de la realidad. Va de 0 a 1, donde 0 es la calibración y precisión perfecta y los valores más altos indican peor desempeño.

$$\text{Brier Score} = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2$$

- N: Número total de observaciones en el set de datos.
- p_i : La probabilidad predicha por el modelo para la instancia i.
- y_i : El resultado real (label) de la instancia i.

MEDICIÓN DE LA CALIBRACIÓN

Para medir la calibración tenemos principalmente dos herramientas.

Brier Score: Matemáticamente, el Brier Score se descompone de:

$$\text{Brier Score} = \text{Calibración} - \text{Discriminación} + \text{Ruido}$$

- Calibración: Qué tan cerca está de la diagonal en el diagrama de calibración
- Discriminación: Qué tanto se alejan las predicciones del promedio global (qué tan bien separas 0s de 1s).

Es decir, no es buena idea comparar el Brier Score entre modelos diferentes dado que si cambia la capacidad de discriminación, tendremos valores diferentes.

VAMOS A PRACTICAR UN POCO...

MÉTODOS DE CALIBRACIÓN

MÉTODOS DE CALIBRACIÓN

Cómo solucionamos los casos de modelos mal calibrados?

Pues construyendo otro modelo que mapee las probabilidades. Un modelo de una sola dimensión:

$$f_{\text{calib}}(s(X)) \approx P(y)$$

Donde: $s(X)$ es el score dado por el modelo. Es decir, podemos usarlos en modelos que no dan salida probabilísticas.

Para entrenar a f_{calib} se puede:

- Usar el set de entrenamiento, pero vamos a overfittear.
- Usar un set distinto al de entrenamiento y evaluación.
- Se puede entrenar usando **validación cruzada**. Más lento pero asegura evitar overfitting.

MÉTODOS DE CALIBRACIÓN

Platt Scaling

Que pasa si ajustamos una regresión logística a la salida del modelo? Transformamos la salida cruda del modelo (score) en una probabilidad asumiendo que la distribución tiene forma de Sigmoide (S).

Entrenamos una regresión logística auxiliar para encontrar los parámetros A (pendiente) y B (sesgo)

$$P(y = 1|X) = \frac{1}{1 + \exp(A \cdot s(X) + B)}$$

Se optimiza por Máxima Verosimilitud (minimizando la Log Loss), igual que una regresión logística estándar.

Caso de Uso

- Funciona excelentemente en modelos de "máximo margen" como SVM.
- Convierte distancias arbitrarias en una probabilidad acotada [0,1].

MÉTODOS DE CALIBRACIÓN

Regresión isotónica

En este caso no asumimos ninguna forma funcional (como una sigmoide). Solo asumimos que si el score del modelo sube, la probabilidad real no debe bajar. Es decir, usamos un modelo **no paramétrico**.

Aprende una función escalonada arbitraria que debe cumplir una única regla: ser monótonamente creciente (nunca baja, solo sube o se mantiene).

- Zonas constantes: Agrupa rangos de scores donde la probabilidad empírica es similar.
- Saltos: Cambia de nivel para ajustarse a los datos.

Para entrenarse se usa el algoritmo **Pool Adjacent Violators Algorithm**: Si un punto tiene una probabilidad menor que el anterior (violando la monotonicidad), los agrupa y promedia hasta que la curva sea creciente. Se busca minimizar:

$$\text{Minimizar: } \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad \text{Sujeto a: } \hat{y}_1 \leq \hat{y}_2 \leq \dots \leq \hat{y}_n$$

MÉTODOS DE CALIBRACIÓN

Regresión isotónica

Veamos un pequeño ejemplo... Tenemos un modelo que predice la probabilidad de que 5 personas compren un producto:

Persona	Score (Modelo)	Compro?	Tiene sentido?
A	0.10	0 (No)	Ok
B	0.40	1 (Si)	Ok
C	0.60	0 (No)	ERROR
D	0.80	1 (Si)	Ok
E	0.9	1 (Si)	Ok

- La persona B (score 0.40) en realidad compró.
- La persona C (score 0.60) no compró. Es decir se rompe la monotonicidad.

El modelo dice que C es más probable que B, pero en realidad ocurrió lo contrario.

MÉTODOS DE CALIBRACIÓN

Regresión isotónica


Entonces para mantener que siga subiendo, tomamos a B y C y promediamos su probabilidad:

Persona	Score (Modelo)	Compro?	Probabilidad isotónica
A	0.10	0 (No)	0
B	0.40	1 (Si)	0.5 (Promedio de $(1 + 0) / 2$)
C	0.60	0 (No)	0.5 (Promedio de $(1 + 0) / 2$)
D	0.80	1 (Si)	1
E	0.9	1 (Si)	1

MÉTODOS DE CALIBRACIÓN

Regresión isotónica

Si vemos, la curva de probabilidad no es sigmoidea, sino va a tener una forma escalonada



MÉTODOS DE CALIBRACIÓN

Comparación rápida:

- **Platt Scaling**: Bueno con pocos datos.
- **Regresión isotónica**: Necesita muchos datos (para no overfittear los escalones), pero se ajusta a cualquier forma.

VAMOS A PRACTICAR UN POCO...

CALIBRACIÓN MULTICLASE

Los métodos clásicos (Platt Scaling, Isotonic Regression) son inherentemente binarios.

Cómo podemos hacer en el caso multiclase? La Solución: *One-vs-Rest*. Para calibrar un clasificador de K clases, descomponemos el problema en K problemas de calibración binaria independientes.

CALIBRACIÓN MULTICLASE

Algoritmo de Calibración Multiclase

1. **Calibración Independiente.** Obtenemos una probabilidad calibrada cruda para cada clase k usando su propio calibrador binario (sea Platt o Isotónico).

$$p_k = f_{calib}^{(k)}(s_k(X))$$

2. Como cada calibrador es independiente, las probabilidades no sumarán 1.

$$\sum_{k=1}^K p_k \neq 1$$

3. **Normalización L1.** Para obtener la probabilidad final $P(y=k | X)$, normalizamos dividiendo cada probabilidad por la suma total:

$$P(y = k | X) = \frac{p_k}{\sum_{j=1}^K p_j}$$

CONCLUSIONES

- La calibración no busca *clasificar mejor*, sino *medir bien la incertidumbre*.
- Un modelo mal calibrado puede ser peligroso en aplicaciones reales.
- Tenemos herramientas que nos ayudan a calibrar de forma rápida.